Sertifikasi BNSP – Salma Nabilah Rouf Associate Data Science 22 Desember 2022

Link Google Colab:

https://colab.research.google.com/drive/1sZklQcTGc0SgqZ7N4zRvYLhHCZofwZcu#scrollTo=LeeOy1epkof4

Link Drive (data clean, collab, dan pdf):

https://drive.google.com/drive/folders/1Duy1SreMd6XQp5akj1Rz6Qt2FEJfm4AY?usp=sharing

Business Understanding

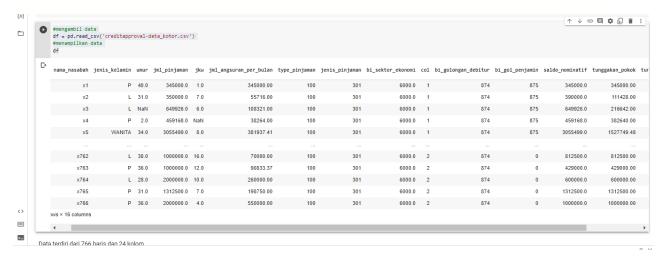
Sumanto seorang kredit analis sebuah Bank ABC sedang memiliki masalah karena banyaknya nasabah yang mengalami kredit macet. Untuk mengantisipasi masalah tersebut, dia mencoba melakukan analisis terhadap data nasabah dan status pembayaran cicilan kreditnya agar dapat memprediksi profile debitur (penghutang) dari aspek lancar atau macet kreditnya.

Tujuan

Untuk memprediksi calon nasabah apakah dapat membayar kredit lancar atau macet berdasarkan data history tahun lalu.(data terlampir)

Data Understanding

```
#import library
import pandas as pd
import numpy as np
```



Data terdiri dari 766 baris dan 24 kolom

```
Pendefinisian Variabel
jenis kelamin = Jenis kelamin terdiri dari P dan L
umur = usia nasabah
jml pinjaman = jumlah pinjaman nasabah
j kw = jangka waktu (bulan)
jml angsuran per bulan = jumlah angsuran yyng harus dibayar tiap bulan
type pinjaman = tipe pinjaman
jenis pinjaman = jenis pinjaman
bi sektor ekonomi = Sektor Ekonomi BI
col
bi_golongan_debitur = golongan debitur
bi gol penjamin = golongan penjamin
saldo nominatif = saldo nominatif nasabah
tunggakan pokok = tunggakan pokok yang harus dibayar nasabah
tunggakan bunga = tunggakan bunga yang harus dibayar nasabah
status kredit = status kredit nasabah
 Ц
 {x}
       #mengecek tipe data
         df.dtypes
 object
       nama_nasabah
         jenis_kelamin
                             object
                           float64
float64
          umur
          jml_pinjaman
                            float64
          jkw
          jml_angsuran_per_bulan float64
```

Dengan rincian

<>

== >_ col

object = data kategorik (berupa string)

tunggakan_pokok tunggakan_bunga

status kredit

dtype: object

type_pinjaman int64 jenis_pinjaman int64 bi_sektor_ekonomi float64

bi_golongan_debitur int64 bi_gol_penjamin int64 saldo_nominatif float64

int64 int64

float64

float64

object

float64 = data numerik

int64 = data numerik integer

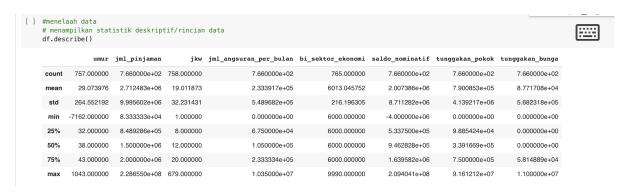
Data Cleaning dan Data Preparation

```
df.nunique()
nama_nasabah
    jenis_kelamin
                             58
    jml_pinjaman
                            328
    jml_angsuran_per_bulan
                            449
    type piniaman
    jenis_pinjaman
    bi_sektor_ekonomi
    bi_golongan_debitur
    bi_gol_penjamin
    saldo nominatif
                            528
    tunggakan pokok
    tunggakan_bunga
    status kredit
    dtype: int64
```

Dapat dilihat terdapat beberapa kolom memiliki tipe data object sedangkan seharusnya adalah category agar lebih efektif karena memiliki jumlah nilai unik sedikit. Kolom tersebut adalah Jenis_Kelamin, type_pinjaman, jenis_pinjaman, bi_sektor_ekonomi, col, bi_go longan debitur, bi gol penjamin, dan kolom status kredit..

```
# Mengumpulkan kolom-kolom yang dingin diubah pada 1 list
kolom_diubah = ['jenis_kelamin', 'type_pinjaman', 'jenis_pinjaman', 'col', 'bi_golongan_debitur', 'bi_gol_penjamin', 'status kredit']
df[kolom_diubah] = df[kolom_diubah].astype('category')
                                 object
jenis_kelamin
                            category
float64
umur float64
jml_pinjaman float64
                               float64
jml_angsuran_per_bulan
type_pinjaman
jenis_pinjaman
                    category
category
bi_sektor_ekonomi
                               float64
                             category
bi_golongan_debitur
bi_gol_penjamin
saldo_nominatif
                              category
tunggakan_pokok
                              float64
tunggakan_bunga
                               float64
status kredit
                              category
dtype: object
```

Tipe data sudah sesuai



```
[] # menampilkan info dari data kredit nasabah
    df.info()
```

<class 'pandas.core.frame.DataFrame'> RangeIndex: 766 entries, 0 to 765 Data columns (total 16 columns):

```
Column
                            Non-Null Count Dtype
#
                            766 non-null
0
    nama_nasabah
                                            object
1
     jenis kelamin
                            766 non-null
                                            category
    umur
                            757 non-null
                                             float64
2
3
     jml_pinjaman
                            766 non-null
                                            float64
                            758 non-null
                                             float64
    jkw
    jml_angsuran_per_bulan 766 non-null
5
                                            float64
6
    type_pinjaman
                            766 non-null
                                            category
7
     jenis_pinjaman
                            766 non-null
                                            category
8
    bi_sektor_ekonomi
                            765 non-null
                                            float64
9
                            766 non-null
    col
                                            category
10 bi_golongan_debitur
                            766 non-null
                                            category
                                            category
11 bi_gol_penjamin
                            766 non-null
12 saldo_nominatif
                            766 non-null
                                             float64
13 tunggakan_pokok
                            766 non-null
                                             float64
14 tunggakan bunga
                            766 non-null
                                             float64
15 status kredit
                            766 non-null
                                            category
dtypes: category(7), float64(8), object(1)
```

memory usage: 60.3+ KB

```
[ ] #memvalidasi data
    #cek missing value
    df.isnull().sum()
```

- nama_nasabah jenis_kelamin 0 9 umur 0 jml_pinjaman jkw 8 jml_angsuran_per_bulan type_pinjaman 0 0 jenis_pinjaman bi_sektor_ekonomi 1 col 0 bi_golongan_debitur 0 bi_gol_penjamin 0 saldo_nominatif 0 tunggakan_pokok 0 tunggakan_bunga 0 status kredit 0 dtype: int64
- terdapat 9 row kolom umur memiliki missing value
- terdapat 8 row kolom jkw memiliki missing value
- terdapat 1 row kolom bi_sektor_ekonomi memiliki missing value

```
[] #mengatasi missing value pada kolom umur
    rata_umur = df['umur'].mean()
    df['umur'] = df['umur'].fillna(rata_umur)
#menangani missing value di kolom jkw
    rata_jkw = df['jkw'].mean()
    df['jkw'] = df['jkw'].fillna(rata_jkw)
[] #menangani missing value di kolom bi_sektor_ekonomi
    rata_bi_sektor_ekonomi = df['bi_sektor_ekonomi'].mean()
    df['bi_sektor_ekonomi'] = df['bi_sektor_ekonomi'].fillna(rata_bi_sektor_ekonomi)
[ ] #mengecek kembali jumlah missing value
    df.isnull().sum()
    nama_nasabah
                               0
    jenis_kelamin
    umur
    jml_pinjaman
                               0
    jkw
    jml_angsuran_per_bulan
                               0
    type_pinjaman
    jenis_pinjaman
                               0
    bi_sektor_ekonomi
    col
    bi_golongan_debitur
    bi_gol_penjamin
    saldo_nominatif
    tunggakan_pokok
    tunggakan_bunga
    status kredit
dtype: int64
```

Data sudah tidak memiliki missing value

```
[ ] #Pengecekan Keunikan data category
     df.nunique()
     nama_nasabah
                                   766
     jenis_kelamin
                                     6
     umur
                                    59
     jml_pinjaman
                                   328
     jkw
                                    52
     jml_angsuran_per_bulan
                                   449
     type_pinjaman
                                     1
     jenis_pinjaman
     bi_sektor_ekonomi
     col
     bi_golongan_debitur
                                     3
     bi_gol_penjamin
     saldo_nominatif
                                   528
     tunggakan_pokok
                                   490
     tunggakan_bunga
                                   142
     status kredit
dtype: int64
[ ] df['jenis_kelamin'].unique()
     ['P', 'L', 'WANITA', 'LAKI-LAKI', 'PRIA', 'PEREMPUAN']
Categories (6, object): ['L', 'LAKI-LAKI', 'P', 'PEREMPUAN', 'PRIA', 'WANITA']
```

terdapat perbedaan pendefinisian jenis kelamin sehingga perlu disamakan menjadi P dan L saja

```
[ ] df["jenis_kelamin"] = df["jenis_kelamin"].str.replace("WANITA", "P")
    df["jenis_kelamin"] = df["jenis_kelamin"].str.replace("PEREMPUAN", "P")
    df["jenis_kelamin"] = df["jenis_kelamin"].str.replace("LAKI-LAKI", "L")

df["jenis_kelamin"] = df["jenis_kelamin"].str.replace("PRIA", "L")

[ ] df["jenis_kelamin"].unique()
    array(['P', 'L'], dtype=object)

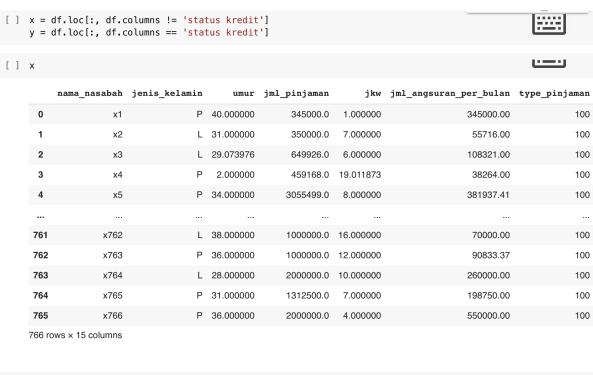
[ ] #mengecek data duplikat
    df.duplicated().sum()

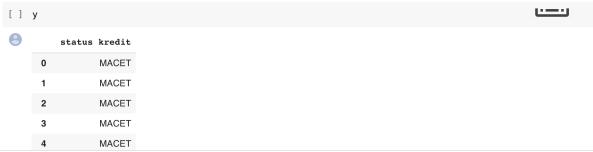
    0

Tidak terdapat data duplikat

[ ] #membuat file csv data bersih
    df.to_csv('data_clean.csv')
```

Modelling





	Description	Value
0	session_id	3348
1	Target	status kredit
2	Target Type	Binary
3	Label Encoded	LANCAR: 0, MACET: 1
4	Original Data	(766, 16)
5	Missing Values	False
6	Numeric Features	8
7	Categorical Features	6
8	Ordinal Features	False
9	High Cardinality Features	False
10	High Cardinality Method	None
11	Transformed Train Set	(536, 27)
12	Transformed Test Set	(230, 27)
13	Shuffle Train-Test	True

+ Code + Text

8

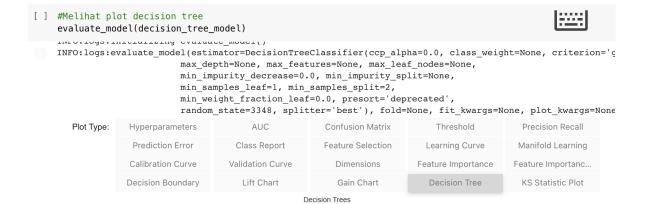
#Pengecekan nilai Accuracy, Precision, F1 Score dengan membandingan menggunakan beragam model compare_models() Ľ> MCC TT (Sec) Model Accuracy AUC Recall Prec. F1 Kappa lightgbm Light Gradient Boosting Machine 0.9571 0.9896 0.9765 0.9649 0.9704 0.8927 0.8945 0.128 Gradient Boosting Classifier 0.9534 0.9876 0.9818 0.9557 0.9682 0.8809 0.8844 gbc 0.124 Ada Boost Classifier 0.9515 0.9811 0.9688 0.9644 0.9663 0.8797 0.8811 0.111 ada rf Random Forest Classifier 0.9495 0.9890 0.9791 0.9538 0.9656 0.8705 0.8756 0.221 0.9254 0.9741 0.9687 0.9316 0.9493 0.8086 0.8143 Extra Trees Classifier 0.182 et Decision Tree Classifier 0.9178 0.9012 0.9399 0.9464 0.9427 0.7971 0.7994 0.015 dt Logistic Regression 0.9105 0.9459 0.9559 0.9252 0.9390 0.7701 0.7785 0.518 Ir knn K Neighbors Classifier 0.9013 0.9517 0.9324 0.9311 0.9312 0.7557 0.7582 0.023 0.8824 0.0000 0.9765 0.8792 0.9239 0.6661 0.6921 SVM - Linear Kernel 0.012 svm Linear Discriminant Analysis 0.8619 0.9071 0.9503 0.8694 0.9080 0.6339 0.6443 0.016 lda Ridge Classifier 0.8434 0.0000 0.9582 0.8452 0.8979 0.5683 0.5897 0.014 ridge 0.014 dummy Dummy Classifier 0.7164 0.5000 1.0000 0.7164 0.8348 0.0000 0.0000 0.5654 0.8059 0.4406 0.9054 0.5795 0.2384 0.3083 qda Quadratic Discriminant Analysis 0.015 0.5038 0.9061 0.3278 0.9369 0.4810 0.1859 0.2855 0.014 nb Naive Bayes INFO:logs:create model container: 14

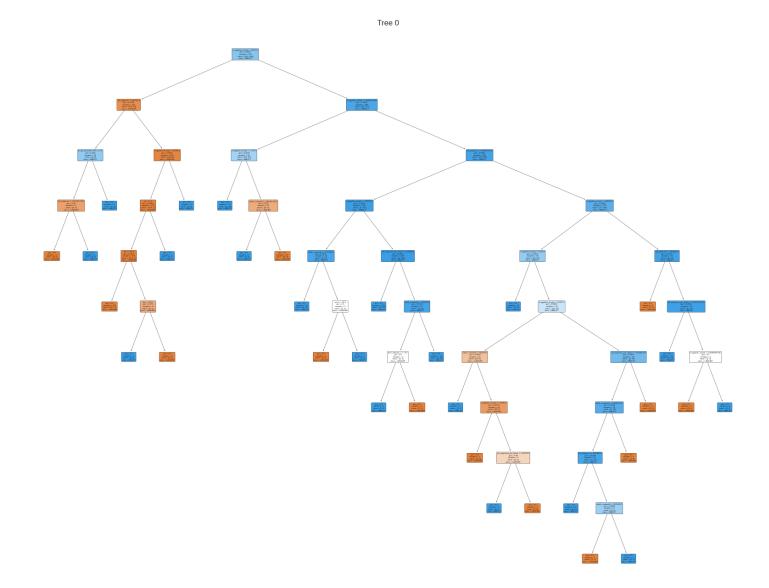
→ Model 1 - Decision Tree

[] decision_tree_model = create_model('dt')
##https://pycaret.readthedocs.io/en/stable/api/classification.html
Accuracy AUC Recall Prec. Fl Kappa MCC

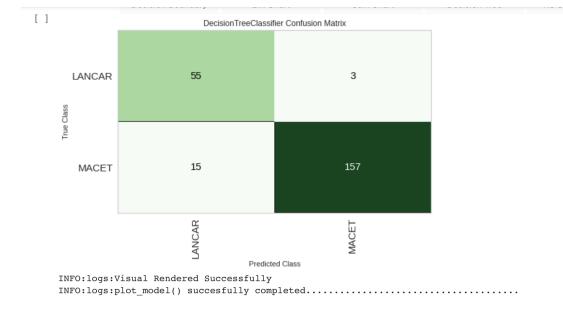
	Accuracy	AUC	Recall	Prec.	F1	Карра	мсс
Fold							
0	0.9630	0.9538	0.9744	0.9744	0.9744	0.9077	0.9077
1	0.9630	0.9538	0.9744	0.9744	0.9744	0.9077	0.9077
2	0.9259	0.9077	0.9487	0.9487	0.9487	0.8154	0.8154
3	0.9259	0.9077	0.9487	0.9487	0.9487	0.8154	0.8154
4	0.8704	0.8174	0.9474	0.8780	0.9114	0.6713	0.6781
5	0.9259	0.9293	0.9211	0.9722	0.9459	0.8286	0.8316
6	0.7925	0.7342	0.8684	0.8462	0.8571	0.4781	0.4786
7	0.9245	0.9272	0.9211	0.9722	0.9459	0.8212	0.8245
8	0.9434	0.9202	0.9737	0.9487	0.9610	0.8577	0.8586
9	0.9434	0.9605	0.9211	1.0000	0.9589	0.8685	0.8761
Mean	0.9178	0.9012	0.9399	0.9464	0.9427	0.7971	0.7994
Std	0.0486	0.0677	0.0315	0.0453	0.0332	0.1237	0.1236
INFO:1	ogs:create ogs:master ogs:displa ogs:Decisi	_model ay_cont	_ _contain ainer: 5	er: 17 er(ccp_ th=None urity_c ples_le ght_fra	e, max_i decrease eaf=1, r action_1	feature e=0.0, m min_sam leaf=0.	s=None, min_imp ples_sp 0, pres

→ Evaluation





Confusion Matrix Decision Tree



- Interpretasi dari Confusion Matrix Decision Tree

True Positive (55)

Interpretasi: Kredit diprediksi lancar dan memang lancar

True Negative (157):

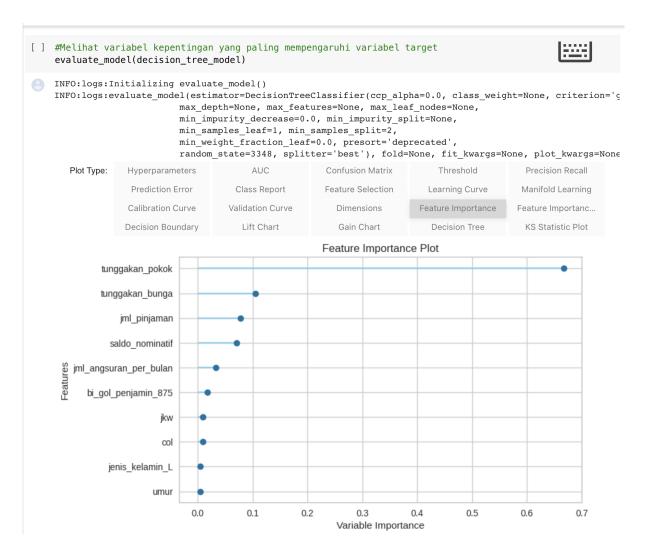
Interpretasi: Kredit diprediksi macet dan kenyataannya memang macet

False Positive (3): (Kesalahan Tipe 1)

Interpretasi: Kredit diprediksi lancar namun ternyata macet

False Negative (15): (Kesalahan Tipe 2, sangat berbahaya)

Interpretasi: Kredit diprediksi macet namun ternyata lancar



Dari hasil tersebut diketahui bahwa variabel tunggakan_pokok memiliki pengaruh paling besar dalam klasifikasi dengan nilai kepentingan tertinggi. Sedangkan variabel bi_sektor_ekonomi mmenempati nilai kepentingan terendah dibandingkan kolom lainnya.

Deployment / Rekomendasi - Decision Tree

```
#Interpretasi model decision tree
    interpret_model(decision_tree_model)
INFO:logs:Initializing interpret_model()
    INFO:logs:interpret model(estimator=DecisionTreeClassifier(ccp alpha=0.0, class weight=None, crite
                             max_depth=None, max_features=None, max_leaf_nodes=None,
                             min_impurity_decrease=0.0, min_impurity_split=None,
                             min_samples_leaf=1, min_samples_split=2,
                             min_weight_fraction_leaf=0.0, presort='deprecated',
                             random_state=3348, splitter='best'), use_train_data=False, X_new_sample=Non
    INFO:logs:Checking exceptions
    INFO:logs:plot type: summary
    INFO:logs:Creating TreeExplainer
    INFO:logs:Compiling shap values
                                                                         High
                    tunggakan_pokok
                    tunggakan_bunga
                        jml_pinjaman
                      saldo_nominatif
                 bi_gol_penjamin_875
               jml_angsuran_per_bulan
                      jenis_kelamin_L
     bi_sektor_ekonomi_6013.0458984375
             bi_sektor_ekonomi_9990.0
                 bi_gol_penjamin_835
                 bi_gol_penjamin_800
                    bi_gol_penjamin_0
              bi_golongan_debitur_876
              bi_golongan_debitur_874
```

Variabel tunggakan pokok memiliki pengaruh paling besar terhadap status kredit, maka dari itu untuk mengantisipasi masalah apakah nantinya nasabah tersebut dapat membayar kredit lancar atau macet perlu ditinjau dan dipertimbangkan kembali khususnya di beberapa feature yang memiliki nilai kepentingan / importance rate yang cukup tinggi.

Model 2 - Random Forest

] randor	m_forest_m	odel =	create_	_model('rf')										Ŀ	 1
9 Fold	Accuracy	AUC	Recall	Prec.	F1	Карра	мсс									
0	0.9630	0.9949	0.9744	0.9744	0.9744	0.9077	0.9077									
1	0.9815	1.0000	1.0000	0.9750	0.9873	0.9529	0.9539									
2	0.9630	0.9821	0.9744	0.9744	0.9744	0.9077	0.9077									
3	0.9815	0.9923	1.0000	0.9750	0.9873	0.9529	0.9539									
4	0.8889	0.9564	0.9737	0.8810	0.9250	0.7128	0.7262									
5	0.9815	0.9967	1.0000	0.9744	0.9870	0.9548	0.9558									
6	0.8679	0.9807	0.9737	0.8605	0.9136	0.6380	0.6605									
7	0.9623	0.9895	0.9737	0.9737	0.9737	0.9070	0.9070									
8	0.9623	0.9974	1.0000	0.9500	0.9744	0.9031	0.9074									
9	0.9434	1.0000	0.9211	1.0000	0.9589	0.8685	0.8761									
Mean	0.9495	0.9890	0.9791	0.9538	0.9656	0.8705	0.8756									
Std	0.0376	0.0126	0.0229	0.0433	0.0247	0.1024	0.0956									
INFO:	logs:create logs:master logs:displa logs:Random	c_model c_model ay_conta	contain ainer: 7 Classifi criteri max_lea min_imp min_sam min_wei n_jobs= warm_st	er: 19 er(boot on='gir f_nodes urity_c ples_le ght_fra -1, ook art=Fal	ni', max s=None, decrease eaf=1, r action_1 p_scores	x_depth max_sa e=0.0, min_sam leaf=0. =False,	=None, mples=N min_imp ples_sp 0, n_es random	max None puri plit stim n_st	ty_s =2, ator	split ss=10 =3348	es='a =Non 00,	uto' e, rbose	,	·		

Evaluasi Model Random Forest



Interpretasi dari Confusion Matrix Random Forest

True Positive (56)

Interpretasi: Kredit diprediksi lancar dan memang lancar

True Negative (169):

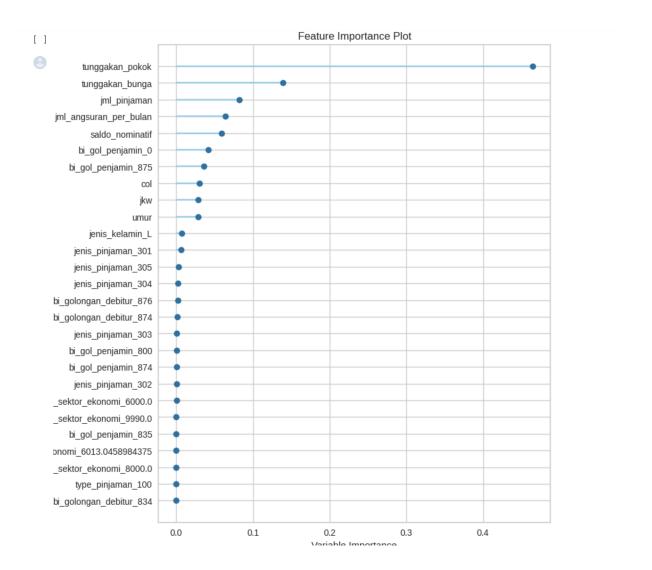
Interpretasi: Kredit diprediksi macet dan kenyataannya memang macet

False Positive (2): (Kesalahan Tipe 1)

Interpretasi: Kredit diprediksi lancar namun ternyata macet

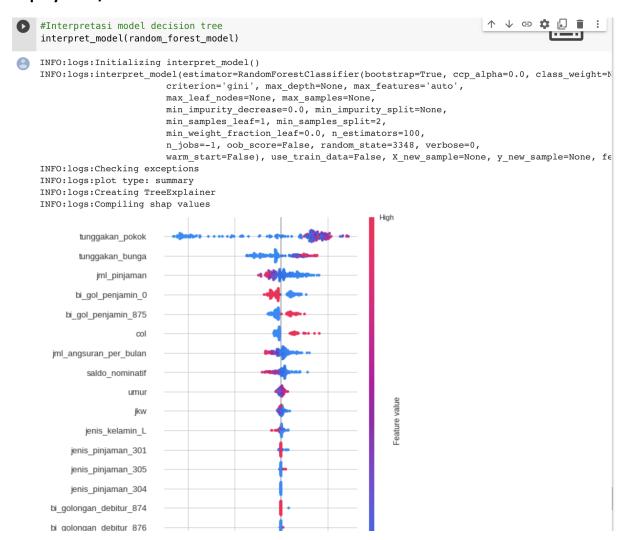
False Negative (3): (Kesalahan Tipe 2, sangat berbahaya)

Interpretasi: Kredit diprediksi macet namun ternyata lancar



Dari hasil tersebut dihasilkan hasil yg sama dengan model decision tree diketahui bahwa variabel tunggakan_pokok memiliki pengaruh paling besar dalam klasifikasi dengan nilai kepentingan tertinggi. Sedangkan variabel bi_sektor_ekonomi mmenempati nilai kepentingan terendah dibandingkan kolom lainnya.

Deployment/ Rekomendasi Random Forest



Karena hasil random forest tidak jauh berbeda dan menghasilkan variabel pengaruh tertinggi (tunggakan_pokok) dan terendah yang sama dengan metode decision tree maka Rekomendasi/Deployment yang diberikan akanlah sama